

演習問題 6.27 解答

高橋優輝

$$\begin{aligned}\ln p(\mathbf{t}_N | \boldsymbol{\theta}) &\approx \ln p(\mathbf{t}_N | \mathbf{a}_N^*) + \ln p(\mathbf{a}_N^* | \boldsymbol{\theta}) - \frac{1}{2} \ln |\mathbf{H}| + \frac{N}{2} \ln(2\pi) \\ &= \ln p(\mathbf{t}_N | \mathbf{a}_N^*) + \ln p(\mathbf{a}_N^* | \boldsymbol{\theta}) - \frac{1}{2} \ln |\mathbf{W}_N(\mathbf{a}_N^*) + \mathbf{C}_N^{-1}| + \frac{N}{2} \ln(2\pi)\end{aligned}\quad (6.90)$$

について、式変形を進める.

今までの議論の中で、(6.80) の成立が分かっている.

$$\ln p(\mathbf{a}_N) + \ln p(\mathbf{t}_N | \mathbf{a}_N) = -\frac{1}{2} \mathbf{a}_N^\top \mathbf{C}_N^{-1} \mathbf{a}_N - \frac{N}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{C}_N| + \mathbf{t}_N^\top \mathbf{a}_N - \sum_{n=1}^N \ln(1 + e^{a_n}) \quad (6.80)$$

(6.90) に (6.80) を代入すると、

$$\begin{aligned}\ln p(\mathbf{t}_N | \boldsymbol{\theta}) &\approx -\frac{1}{2} (\mathbf{a}_N^*)^\top \mathbf{C}_N^{-1} \mathbf{a}_N^* - \frac{N}{2} \ln(2\pi) - \frac{1}{2} \ln |\mathbf{C}_N| + \mathbf{t}_N^\top \mathbf{a}_N^* - \sum_{n=1}^N \ln(1 + e^{a_n^*}) \\ &\quad - \frac{1}{2} \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}| + \frac{N}{2} \ln(2\pi) \\ &= -\frac{1}{2} (\mathbf{a}_N^*)^\top \mathbf{C}_N^{-1} \mathbf{a}_N^* - \frac{1}{2} \ln |\mathbf{C}_N| + \mathbf{t}_N^\top \mathbf{a}_N^* - \sum_{n=1}^N \ln(1 + e^{a_n^*}) - \frac{1}{2} \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}| \\ &\quad (*)\end{aligned}$$

対数尤度関数の最大化のために、 $\boldsymbol{\theta}$ による微分を求めたい. f を $\boldsymbol{\theta}$ と $\boldsymbol{\theta}$ に依存する \mathbf{a}_N^* の関数とすると、

$$\frac{df}{d\theta_j} = \frac{\partial f}{\partial \theta_j} + \frac{\partial f}{\partial \mathbf{a}_N^*} \cdot \frac{d\mathbf{a}_N^*}{d\theta_j}$$

が成り立つ.

$\frac{\partial f}{\partial \theta_j}$ の計算

\mathbf{a}_N^* は $\boldsymbol{\theta}$ に依存することに注意して, \mathbf{a}_N^* を固定して, θ_j で偏微分する. ここで, 次の (C.21), (C.22) を用いる.

$$\frac{\partial}{\partial x}(\mathbf{A}^{-1}) = -\mathbf{A}^{-1} \frac{\partial \mathbf{A}}{\partial x} \mathbf{A}^{-1} \quad (\text{C.21})$$

$$\frac{\partial}{\partial x} \ln |\mathbf{A}| = \text{Tr} \left(\mathbf{A}^{-1} \frac{\partial \mathbf{A}}{\partial x} \right) \quad (\text{C.22})$$

第 1 項

$$\frac{\partial}{\partial \theta_j} ((\mathbf{a}_N^*)^\top \mathbf{C}_N^{-1} \mathbf{a}_N^*) = -(\mathbf{a}_N^*)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \mathbf{C}_N^{-1} \mathbf{a}_N^*$$

第 2 項

$$\frac{\partial}{\partial \theta_j} \ln |\mathbf{C}_N| = \text{Tr} \left(\mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right)$$

第 5 項

$$\begin{aligned} \frac{\partial}{\partial \theta_j} \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}| &= \text{Tr} \left((\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \frac{\partial}{\partial \theta_j} (\mathbf{W}_N + \mathbf{C}_N^{-1}) \right) \\ &= -\text{Tr} \left((\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \mathbf{C}_N^{-1} \right) \\ &= -\text{Tr} \left(\mathbf{C}_N^{-1} (\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \quad (\because \text{トレース作用素の循環性}) \end{aligned}$$

よって,

$$\begin{aligned}
\frac{\partial}{\partial \theta_i} \ln p(\mathbf{t}_N \mid \boldsymbol{\theta}) &= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \left(\text{Tr} \left(\mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) - \text{Tr} \left(\mathbf{C}_N^{-1} (\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \right) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left(\mathbf{C}_N^{-1} (\mathbf{I} - (\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \mathbf{C}_N^{-1}) \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left(\mathbf{C}_N^{-1} (\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} ((\mathbf{W}_N + \mathbf{C}_N^{-1}) - \mathbf{C}_N^{-1}) \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left(\mathbf{C}_N^{-1} (\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \mathbf{W}_N \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left(((\mathbf{W}_N + \mathbf{C}_N^{-1}) \mathbf{C}_N)^{-1} \mathbf{W}_N \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \quad (\because (\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left((\mathbf{W}_N \mathbf{C}_N + \mathbf{I})^{-1} \mathbf{W}_N \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \\
&= \frac{1}{2} \left((\mathbf{a}_N^\star)^\top \mathbf{C}_N^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_i} \mathbf{C}_N^{-1} \mathbf{a}_N^\star \right) \\
&\quad - \frac{1}{2} \text{Tr} \left((\mathbf{C}_N \mathbf{W}_N + \mathbf{I})^{-1} \mathbf{W}_N \frac{\partial \mathbf{C}_N}{\partial \theta_j} \right) \quad (\because \mathbf{W}_N: \text{対角行列}) \quad (6.91)
\end{aligned}$$

$$\boxed{\frac{\partial f}{\partial \mathbf{a}_N^*} \cdot \frac{d\mathbf{a}_N^*}{d\theta_j} \text{ の計算}}$$

今,

$$\Psi(\mathbf{a}_N) := \ln p(\mathbf{a}_N) + \ln p(\mathbf{t}_N | \mathbf{a}_N) \quad (6.80)$$

はラプラス近似によって,

$$\frac{\partial}{\partial \mathbf{a}_N^*} \Psi(\mathbf{a}_N^*) = \mathbf{0}$$

となるように近似されているので,

$$\left(\frac{\partial}{\partial \mathbf{a}_N^*} \ln p(\mathbf{t}_N | \boldsymbol{\theta}) \right) \cdot \frac{d\mathbf{a}_N^*}{d\theta_j} = -\frac{1}{2} \sum_{n=1}^N \frac{\partial \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}|}{\partial a_n^*} \frac{\partial a_n^*}{\partial \theta_j} \quad (**)$$

となる. ここで,

$$\begin{aligned} \frac{\partial \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}|}{\partial a_n^*} &= \text{Tr} \left((\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \frac{\partial}{\partial a_n^*} (\mathbf{W}_N + \mathbf{C}_N^{-1}) \right) \\ &= \text{Tr} \left((\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} \frac{\partial \mathbf{W}_N}{\partial a_n^*} \right) \quad (\because \mathbf{C}_N : \mathbf{a}_N \text{ に非依存}) \quad (***) \end{aligned}$$

が成り立つ. さらに,

$$(\mathbf{W}_N + \mathbf{C}_N^{-1})^{-1} = (\mathbf{I} + \mathbf{C}_N \mathbf{W}_N)^{-1} \mathbf{C}_N$$

であり,

$$\begin{aligned} \frac{\partial \mathbf{W}_N}{\partial a_n^*} &= \frac{\partial}{\partial a_n^*} \text{diag} \left([\sigma(a_1^*)(1 - \sigma(a_1^*)) \quad \cdots \quad \sigma(a_n^*)(1 - \sigma(a_n^*)) \quad \cdots \quad \sigma(a_N^*)(1 - \sigma(a_N^*))] \right) \\ &= \text{diag} \left([0 \quad \cdots \quad \sigma(a_n^*)(1 - \sigma(a_n^*))(1 - 2\sigma(a_n^*)) \quad \cdots \quad 0] \right) \quad (\because \frac{d\sigma}{da} = \sigma(1 - \sigma) \quad (4.88)) \end{aligned}$$

であるので, (***) に代入して,

$$\frac{\partial \ln |\mathbf{W}_N + \mathbf{C}_N^{-1}|}{\partial a_n^*} = ((\mathbf{I} + \mathbf{C}_N \mathbf{W}_N)^{-1} \mathbf{C}_N)_{nn} \sigma(a_n^*)(1 - \sigma(a_n^*))(1 - 2\sigma(a_n^*))$$

が成り立つ. これを (**) に代入すると,

$$\left(\frac{\partial}{\partial \mathbf{a}_N^*} \ln p(\mathbf{t}_N | \boldsymbol{\theta}) \right) \cdot \frac{d\mathbf{a}_N^*}{d\theta_j} = -\frac{1}{2} \sum_{n=1}^N ((\mathbf{I} + \mathbf{C}_N \mathbf{W}_N)^{-1} \mathbf{C}_N)_{nn} \sigma(a_n^*)(1 - \sigma(a_n^*))(1 - 2\sigma(a_n^*)) \frac{\partial a_n^*}{\partial \theta_j} \quad (6.92)$$

が得られる.

また,

$$\begin{aligned}
\frac{\partial \mathbf{a}_N^*}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} (\mathbf{C}_N (\mathbf{t}_N - \boldsymbol{\sigma}_N)) \\
&= \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) + \mathbf{C}_N \frac{\partial}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) \\
&= \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) - \mathbf{C}_N \frac{\partial \boldsymbol{\sigma}_N}{\partial \theta_j} \quad (\because \mathbf{t}_N \text{ は } \theta_j \text{ に非依存})
\end{aligned}$$

ここで,

$$\begin{aligned}
\frac{\partial \boldsymbol{\sigma}_N}{\partial \theta_j} &= \begin{bmatrix} \frac{\partial \sigma(a_1^*)}{\partial \theta_j} \\ \vdots \\ \frac{\partial \sigma(a_N^*)}{\partial \theta_j} \end{bmatrix} \\
&= \begin{bmatrix} \frac{\partial \sigma(a_1^*)}{\partial a_1^*} \frac{\partial a_1^*}{\partial \theta_j} \\ \vdots \\ \frac{\partial \sigma(a_N^*)}{\partial a_N^*} \frac{\partial a_N^*}{\partial \theta_j} \end{bmatrix} \\
&= \begin{bmatrix} \sigma(a_1^*) (1 - \sigma(a_1)^*) \frac{\partial a_1^*}{\partial \theta_j} \\ \vdots \\ \sigma(a_N^*) (1 - \sigma(a_N)^*) \frac{\partial a_N^*}{\partial \theta_j} \end{bmatrix} \\
&= \text{diag}([\sigma(a_1^*) (1 - \sigma(a_1)^*) \quad \cdots \quad \sigma(a_N^*) (1 - \sigma(a_N)^*)]) \frac{\partial \mathbf{a}_N^*}{\partial \theta_j} \\
&= \mathbf{W}_N \frac{\partial \mathbf{a}_N^*}{\partial \theta_j}
\end{aligned}$$

であるので,

$$\frac{\partial \mathbf{a}_N^*}{\partial \theta_j} = \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) - \mathbf{C}_N \mathbf{W}_N \frac{\partial \mathbf{a}_N^*}{\partial \theta_j} \quad (6.93)$$

が成り立つ. これを並び替えると,

$$\frac{\partial \mathbf{a}_N^*}{\partial \theta_j} = (\mathbf{I} + \mathbf{W}_N \mathbf{C}_N)^{-1} \frac{\partial \mathbf{C}_N}{\partial \theta_j} (\mathbf{t}_N - \boldsymbol{\sigma}_N) \quad (6.94)$$

が得られる. 以上, (6.91), (6.92), (6.94) を組み合わせることで, 対数尤度関数の勾配を求めることができる.